



تمارين ديتا ساينس

هفته سوم

تابستان ۱۴۰۴

قبل از این که به بحث شیرین تمارین برسیم، لازمه که چند تا نکته رو در رابطه با تمارین بدونید:

- در این تمرین، تعدادی سوال در اختیار شما قرار گرفته است.
- اولویت اول ما و شما، یادگیری شماست. پس تلاش کنید به جای حل سوالاتی که چالشی برای شما ندارد به سراغ سوالات چالشی‌تر برای خودتان بروید تا بتوانید یادگیری خودتان را افزایش دهید.
- زمان تحویل جمعه ۱۱ مهر ماه میباشد. (ساعت ۹ شب)
- ددلاین تمرین به هیچ عنوان تغییر نخواهد کرد.
- گروه بندی در انتهای تمرین انجام شده است.
- تمرینا رو برای منتور(نوا) ارسال کنید. (فایل های ارسالی رو با اسم خودتون بفرستید).

Telegram: @n80a90zh94

- در صورت داشتن سوال در رابطه با تمرین یا نیاز به راهنمایی، می توانید به آدرس تلگرام زیر پیام بدهید.

Telegram: @mahdavian_a

Telegram: @n80a90zh94

Telegram: @alistelegramid

سوالات گروهی:

دیتاست Titanic یکی از مشهورترین مجموعه داده‌های دنیای یادگیری ماشین است که اطلاعات مربوط به مسافران کشتی تایتانیک را شامل می‌شود. این کشتی در سال ۱۹۱۲ غرق شد و بخشی از مسافران آن نجات یافتند و بخشی دیگر جان باختند. هدف اصلی این دیتاست، پیش‌بینی احتمال زنده ماندن یک مسافر بر اساس ویژگی‌های مختلف اوست.

• = فوت شده و ۱ = زنده مانده (متغیر هدف) Survived

۱. پیش‌پردازش داده (Data Preprocessing) در این بخش داده خام بررسی و آماده‌سازی می‌شود:

- بررسی مقادیر گم‌شده (Missing Values) و تصمیم‌گیری درباره‌ی جایگزینی یا حذف.
- تبدیل داده‌های متنی/دسته‌ای (Sex, Embarked, Pclass) به داده‌های عددی با One-Hot Encoding یا Label Encoding.
- به طور خلاصه بررسی کنید چه کارهایی برای پیش‌پردازش داده باید انجام دهید. و سپس آن‌ها را انجام دهید.
- بررسی کنید نرمال‌سازی یا استانداردسازی چیست؟ آیا نرمال‌سازی یا استانداردسازی ویژگی‌های عددی مثل Age, Fare اینجا لازم است؟ چرا؟ توضیح دهید. (راهنمایی: بعضی مدل‌ها به مقیاس حساس هستند)
- توزیع کلاس هدف (Survived) را بررسی کنید و نسبت مسافران نجات‌یافته به فوت‌شده را گزارش دهید. توضیح دهید که این بالانس یا عدم بالانس چه تأثیری روی انتخاب معیارهای ارزیابی دارد.
- برای هر ویژگی مشخص کنید: آیا Outlier آن باید حذف شود یا باید نگه داشته شود (اگر معنای واقعی دارد و می‌تواند روی مدل اثر مثبت بگذارد. مثلاً بلیت خیلی گران می‌تواند نشانه سفر در کابین VIP باشد و احتمال بقا را زیاد کند). یا باید تبدیل شود؟ (مثلاً با Log Transformation برای کاهش اثر عددهای خیلی بزرگ).
- نمودارهای مناسب مانند توزیع کلاس هدف و توزیع سن‌ها را رسم کنید. چه نمودارهای دیگری می‌توان رسم کرد؟ چه مطالبی می‌توان با تصویرسازی به دست بیاورید؟

۲. تقسیم‌بندی داده‌ها (Train/Test Split)

- داده را به دو بخش Train و Test تقسیم شود.
- معمولاً ۷۰٪ برای Train و ۲۰٪ برای Test و ۱۰٪ برای Validation استفاده می‌شود.
- فقط از Train و Validation برای آموزش مدل و تنظیم پارامترها استفاده کنید. از تست فقط برای ارزیابی نهایی مدل استفاده کنید.
- برای پایداری نتایج از پارامتر random_state در تابع train_test_split استفاده کنید. (چرا؟)

۳. مهندسی ویژگی‌ها (Feature Engineering)

- بررسی توزیع این ویژگی‌ها و ارتباطشان با متغیر هدف (Survived)
- انتخاب ویژگی‌های مهم برای مدل‌سازی. (مثلاً برای انتخاب ویژگی‌ها از رویکرد آماری استفاده کنید. مثال : ویژگی‌هایی با $p\text{-value} > 0.05$ را حذف کنید. همچنین می‌توانید از همبستگی (Correlation) برای بررسی وابستگی متغیرها به متغیر هدف استفاده کنید. در مدل‌های خطی مثل Logistic Regression یا رگرسیون خطی، ضرایب و منظم‌سازی ($L1/L2$) هم ابزار خوبی برای انتخاب ویژگی‌ها هستند.

۴. مدلسازی (Modeling)

- Logistic Regression

- مدل بدون Regularization را با مدل های L_1 (Lasso) و L_2 (Ridge) مقایسه کنند. چه تفاوتی در ضرایب ویژگی ها بین L_1 و L_2 می بینید؟ چرا L_1 باعث صفر شدن برخی ضرایب می شود و به انتخاب ویژگی (Feature Selection) کمک می کند؟ وقتی ویژگی ها همبستگی زیادی دارند، چرا Ridge بهتر از Lasso عمل می کند؟

- ابتدا راجع به تفسیر ضرایب (interpret coefficients) بخوانید و بگویید چیست و چه کاربردی دارد؟ و سپس انجام دهید.

- k-Nearest Neighbors (k-NN)

- انتخاب مقدار مناسب k (بررسی کنید چگونه بهترین مقدار را پیدا کنیم؟ نمودار آن را رسم کنید).
- مقایسه معیارهای فاصله مختلف.

- Support Vector Machine (SVM) : (اختیاری)

- امتحان Kernel های مختلف (Linear, RBF)
- مقایسه اثر هایپرپارامتر C و γ

- و هر مدل ای که دوست دارید آزمایش کنید. (اختیاری)

۵. ارزیابی و تحلیل (Evaluation & Analysis)

- محاسبه معیارهای ارزیابی: (ابتدا مفاهیم را بررسی کنید و یاد بگیرید).

- Accuracy
- Precision, Recall, F1-Score
- Confusion Matrix

- مقایسه عملکرد مدل های مختلف (ابتدا هر مدل را ارزیابی کنید و سپس مدل ها را با هم مقایسه کنید).

- تحلیل ویژگی ها: کدام ویژگی ها بیشترین نقش در پیش بینی بقا داشته اند؟

- بررسی Overfitting/Underfitting با نمودارهای یادگیری یا Cross Validation.

۶. گزارش و تحویل پروژه (Report & Submission)

- معرفی پروژه : توضیح کوتاه درباره دیتاست Titanic و هدف آن.
- مراحل انجام کار : پیش پردازش، تقسیم بندی داده، مهندسی ویژگی ها، مدلسازی و ارزیابی.
- نتایج و تحلیل ها : جدول یا نمودار مقایسه مدل ها.
- جمع بندی و نتیجه گیری : کدام مدل بهترین عملکرد را داشت؟ چه درس هایی از داده گرفتید؟
- چه کارهای دیگری می توان برای بهبود دقت مدل انجام داد؟

سوالات فردی:

1. Can gradient descent get stuck in a local minimum when training a logistic regression model?
2. Suppose you are using polynomial regression. You plot the learning curves and you notice that there is a large gap between the training error and the validation error. What is happening? What are three ways to solve this?
3. Interpret the odds ratio in logistic regression: what does a coefficient of +2 vs -0.5 really mean in practical terms?
4. Why is regularization critical in logistic regression with high-dimensional sparse features (like text)? How do L1 and L2 penalties impact feature interpretability differently?
5. Can logistic regression handle non-linear decision boundaries? If so, how? If not, why?
6. How would you adapt kNN for categorical or mixed data types?
7. Logistic regression and k-NN are both classifiers but conceptually opposite (global parametric vs local instance-based). Under what dataset conditions would you choose one over the other?
8. Compare how overfitting manifests in logistic regression vs k-NN.
9. In regression tasks, when does mean absolute error (MAE) give a more reliable picture than mean squared error (MSE), and vice versa?
10. Imagine you want interpretability and robustness simultaneously — which classifier/regression models would you avoid, and which would you favor? Why?

گروه بندی:

گروه ۱ : جواد و فاضل و نگین
گروه ۲ : علی و نازنین و داوود
گروه ۳ : سهیل و لیلی و آرش
گروه ۴ : پرین و محمد امین

